Universidad de Buenos Aires

Facultad de Ciencias Exactas y Naturales

Maestría en Minería de Datos y Descubrimiento del Conocimiento

Modelos de Predicción en el Contexto del Cáncer de Mama

Tomás González Garello

Trabajo Final Integrador - Especialización en Minería de Datos

Agosto 2025

Índice

Índice **2**
Resumen **3**
Introducción **4**
Contexto y motivación científica 4
Objetivo del trabajo 4
Marco teórico **5**
Antecedentes 5
Metodología **6**
Presentación y descripción de los datos utilizados 6
Preprocesamiento y limpieza de los datos 6
Análisis exploratorio de datos (AED) 6
Entrenamiento de los modelos 7
Software y librerías para la implementación de los modelos 7
Resultados y Discusión **8**
AED, preprocesamiento y segregación de la base 8
Modelos de Clasificación 9
Discusión 10
Limitaciones y perspectivas futuras 11
Conclusión **12**
Bibliografía **13**
Anexo **14**
Material Suplementario 14
Métricas Utilizadas 17
Precision 17
Recall 17
F1-score 17
Código 17

Resumen

En el presente trabajo se encuentran puestas en práctica diversas herramientas adquiridas y trabajadas en las múltiples instancias de aprendizaje propuestas durante el primer año de la maestría. Como caso de estudio, utilizamos un *dataset* del ámbito del aprendizaje automático aplicado a la salud: el conjunto de datos *Wisconsin Diagnostic Breast Cancer*, que contiene información morfológica de células mamarias obtenidas mediante citología por aspiración con aguja fina. El objetivo fue comparar distintos modelos supervisados capaces de clasificar tumores como benignos o malignos a partir de variables numéricas asociadas a las imágenes celulares. Trabajamos con cuatro algoritmos de clasificación —Regresión Logística, *Random Forest, Boosting* y SVM—, siguiendo un protocolo que incluyó validación cruzada para la selección de puntos de corte óptimos. El desempeño de cada modelo se evaluó posteriormente sobre un conjunto de validación, utilizando métricas como *F1-score, precision* y *recall*. SVM y *Boosting* mostraron un desempeño destacado: SVM alcanzó los valores más altos de *F1-score* y *precision* mientras que *Boosting* el *recall* más alto, mostrando cómo cada modelo resalta distintos aspectos de la clasificación. Este trabajo demuestra el potencial de aplicar herramientas de aprendizaje automático a problemas de diagnóstico médico, apoyando decisiones más rápidas y confiables

Introducción

Contexto y motivación científica

El cáncer de mama constituye una de las principales causas de morbilidad y mortalidad en mujeres a nivel mundial, representando una carga significativa tanto para los sistemas de salud como para las personas afectadas (World Health Organization, 2024). La detección temprana de este tipo de tumores es un factor determinante en el pronóstico de la enfermedad, ya que permite iniciar tratamientos oportunos y menos invasivos, lo que se traduce en una mayor tasa de supervivencia (Marmot, 2013). En este marco, la citología por aspiración con aguja fina (FNA, por sus siglas en inglés) se ha consolidado como una técnica diagnóstica clave (Kocjan *et al.*, 2008). Su carácter rápido, económico y mínimamente invasivo la convierte en una herramienta de gran utilidad para el tamizaje inicial de lesiones mamarias sospechosas. Con el avance de la digitalización y el procesamiento de imágenes médicas, ha cobrado relevancia el desarrollo de sistemas computacionales capaces de extraer características morfológicas de las células analizadas mediante FNA. El análisis automatizado de estas imágenes no busca reemplazar al profesional médico, sino complementar el proceso diagnóstico mediante algoritmos que detecten patrones y reduzcan el riesgo de error humano. En este contexto, el uso de modelos estadísticos y técnicas de aprendizaje automático se presenta como una estrategia prometedora para clasificar tumores en función de características morfológicas objetivas, favoreciendo decisiones clínicas más rápidas.

Objetivo del trabajo

El presente trabajo tiene como objetivo principal comparar la capacidad predictiva de diferentes modelos supervisados implementados para la clasificación de tumores mamarios como malignos o benignos.

Marco teórico

Antecedentes

El uso de técnicas de aprendizaje automático ha cobrado cada vez mayor relevancia en el ámbito médico, particularmente en el diagnóstico asistido por computadora en oncología. En el caso del cáncer de mama, numerosos estudios han explorado la posibilidad de automatizar la clasificación de tumores como benignos o malignos mediante algoritmos predictivos aplicados a datos morfológicos obtenidos por citología por FNA. Este enfoque, centrado en atributos celulares observados a nivel microscópico, ha demostrado ser altamente efectivo para detectar anomalías que podrían pasar inadvertidas en evaluaciones clínicas convencionales. Por ejemplo, Islam y colaboradores emplearon modelos como *feed-forward neural networks* (FFNN), k-NN, *Support Vector Machine* (SVM) y Naïve Bayes sobre atributos nucleares derivados de muestras FNA, obteniendo un *accuracy* de hasta 98.10 %, con FFNN superando en rendimiento a SVM (Islam *et al*, 2024). Por su parte, Khandoker Humayoun Kobir y colaboradores evaluaron algoritmos individuales y métodos ensemble —incluyendo *Voting, Bagging* y *Stacking*— sobre el dataset WDBC, reportando un *accuracy* de 99.42 % para el clasificador *Voting* ensemble, y de aproximadamente 98 % para SVM (Khandoker Humayoun Kobir *et al,* 2024). En otro estudio, utilizaron SVM con *kernel* RBF optimizado, alcanzando un *accuracy* de aproximadamente 99 %, *recall* de 97.8 % y *F1-score* de 98.3 % (Hall *et al*, 2022). Finalmente, otro estudio logró combinar *Linear Discriminant Analysis* con SVM para clasificar tumores en los conjuntos WBCD y WPBC, logrando un accuracy de 99.2 %, con *precision* y *recall* cercanos al 98 % (Egwom *et al*, 2022). En síntesis, la literatura previa sugiere que los modelos basados en aprendizaje automático logran desempeños muy altos en términos de *F1-score* y *recall* al trabajar con datos citológicos. Esto los posiciona como herramientas útiles en el contexto del diagnóstico precoz del cáncer de mama.

Metodología

Presentación y descripción de los datos utilizados

El presente trabajo se basa en el conjunto de datos Wisconsin Diagnostic Breast Cancer (WDBC), ampliamente utilizado en investigaciones de aprendizaje automático orientadas al diagnóstico médico (Wolberg, W *et al*, 1993). Esta base contiene información de 569 pacientes que se sometieron a estudios citológicos mediante FNA. Cada observación corresponde a una paciente, e incluye un diagnóstico clínico categorizado como benigno (n = 357) o maligno (n = 212), junto con un conjunto de variables numéricas que describen características morfológicas de las células observadas en la muestra. Las variables originales comprenden un total de 30 atributos derivados de imágenes digitales, calculados sobre el núcleo celular y agrupados en tres tipos de medidas estadísticas (media, error estándar y valor máximo).

Preprocesamiento y limpieza de los datos

Previo al ajuste de los modelos de clasificación, se realizaron diversas etapas de preprocesamiento para garantizar la calidad del análisis y la comparabilidad entre algoritmos. En primer lugar, seleccionamos únicamente variables de "valor medio", correspondiente a diez características morfológicas: radio, textura, perímetro, área, suavidad, compacidad, concavidad, cantidad de puntos cóncavos, simetría y dimensión fractal, todas medidas sobre la forma y estructura de las células tumorales; todas variables numéricas. Así, sumadas a la variable de identificador único de cada paciente y la variable de diagnóstico, la base final cuenta con 12 variables. Dado que algunos algoritmos son sensibles a la escala de las variables, particularmente SVM, se aplicó una normalización previa de las variables numéricas antes del entrenamiento de dicho modelo. La transformación se realizó utilizando escalado *min-max*, reescalando cada variable en el rango [0,1]. Adicionalmente, para el modelo de SVM, se estableció como criterio metodológico la eliminación de variables altamente colineales. Esta decisión se basa en la sensibilidad del algoritmo a la redundancia informativa entre predictores, dado relaciones lineales fuertes que podrían inducir problemas de sobreajuste, lo que finalmente afecta negativamente su capacidad de generalización.

Análisis exploratorio de datos (AED)

Construimos gráficos de cajas para comparar la distribución de las 10 variables numéricas según el diagnóstico, discriminando entre tumores benignos y malignos. Asimismo, construimos un mapa de correlaciones para identificar relaciones lineales entre las covariables y detectar posibles colinealidades fuertes. Estas visualizaciones facilitan la interpretación inicial de los datos y la selección de variables para el modelado posterior.

Entrenamiento de los modelos

Este trabajo se enmarca en el aprendizaje supervisado para clasificación binaria, buscando predecir si un tumor es benigno o maligno a partir de variables morfológicas citológicas. Se seleccionaron cuatro algoritmos ampliamente usados en problemas de clasificación en el contexto de investigación clínica: RL, *Random Forest* (RF), *Boosting* y SVM, cada uno con características que permiten abordar distintos patrones en los datos. Luego, se procedió a la división del conjunto de datos en dos subconjuntos: un conjunto de entrenamiento compuesto por el 80 % de los casos, y un conjunto de validación con el 20 % restante. Esta división aleatoria se llevó a cabo manteniendo la proporción original entre diagnósticos benignos y malignos, con el fin de preservar la representatividad de ambas clases. Durante el entrenamiento de cada modelo, se aplicó una validación cruzada de 5 pliegues, que ofrece una estimación más robusta y generalizable del rendimiento del modelo, y se determinó un punto de corte óptimo para la clasificación, basado en la maximización del *F1-score* promedio de las 5 realizaciones con cada algoritmo. Una vez seleccionado el umbral óptimo, los modelos se reentrenaron sobre la totalidad del conjunto de entrenamiento y se evaluaron en el conjunto de validación, reportando las métricas finales de *F1-score, precision* y *recall* (anexo) para valorar su desempeño. Dado el contexto del estudio, minimizar los falsos negativos es fundamental en este escenario, en donde omitir un diagnóstico positivo podría implicar retrasos críticos en el tratamiento y consecuencias graves para la salud de la paciente. Es por esto que si bien el *F1-score* ofrece una medida equilibrada del rendimiento general del modelo y resulta útil para comparar globalmente el desempeño entre algoritmos, el *recall, que* refleja la capacidad del modelo para identificar correctamente los casos positivos, adquiere un peso prioritario en el presente estudio.

Software y librerías para la implementación de los modelos

Todo el proceso de preprocesamiento de datos, AED, entrenamiento y evaluación de los modelos, así como la generación de gráficos y tablas, se realizó mediante código escrito en *Python*. Se utilizaron bibliotecas especializadas para ciencia de datos y *machine learning*, como *pandas*, *scikit-learn*, *matplotlib* y *seaborn*, entre otras. Esto permitió automatizar el flujo de trabajo y garantizar la reproducibilidad del análisis. Para facilitar la revisión y replicación del estudio, el código completo y detallado está disponible en el Anexo.

Resultados y Discusión

AED, preprocesamiento y segregación de la base

El análisis exploratorio mostró que la mayoría de las variables morfológicas seleccionadas presentan diferencias claras entre tumores benignos y malignos, con excepción de la dimensión fractal media (Figuras 1 y Figuras Suplementarias A y B). El mapa de correlaciones evidenció alta colinealidad entre algunas variables, especialmente entre radio, área y perímetro, así como entre compacidad, concavidad y cantidad de puntos cóncavos. En el caso particular del modelo SVM, se excluyeron radio medio, área media y perímetro medio, debido a su fuerte correlación mutua (coeficientes de correlación > 0.95) y con otras variables, como puntos de concavidad (Figura 2). Luego del filtrado y selección de variables, la base final utilizada para el análisis estuvo compuesta por 569 observaciones completas, correspondientes a pacientes con diagnóstico confirmado de tumor mamario: 357 benignos y 212 malignos. A la vez, el tamaño final de los conjuntos de entrenamiento y de validación fue respectivamente 455 casos y 114 casos.

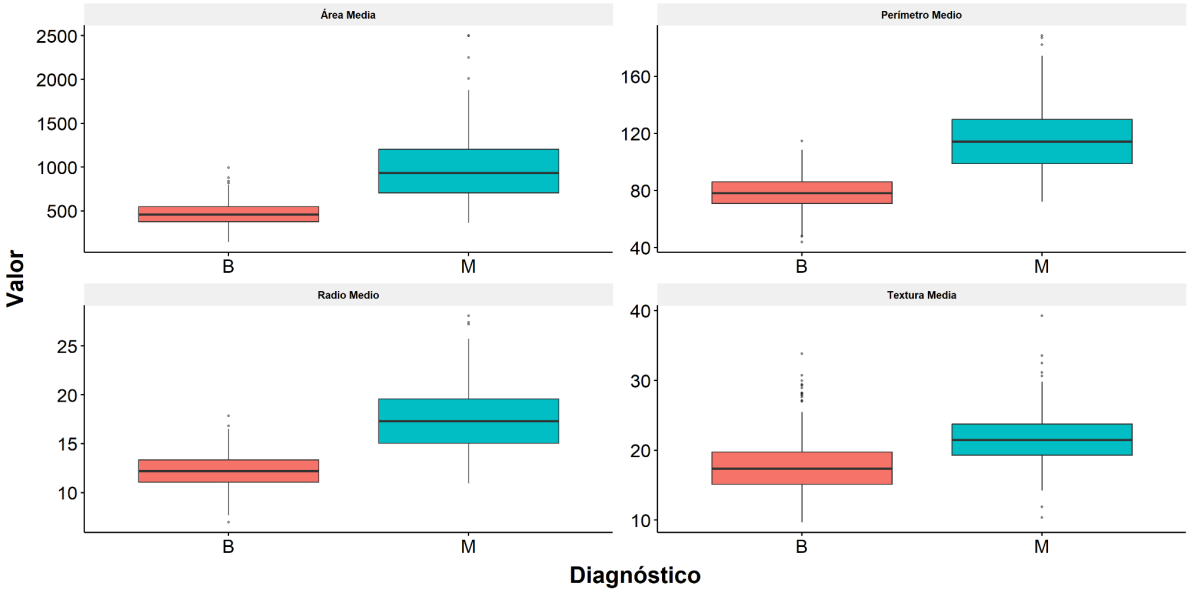

Figura 1. Gráfico de cajas respecto de las variables referidas discriminado según el diagnóstico del tumor

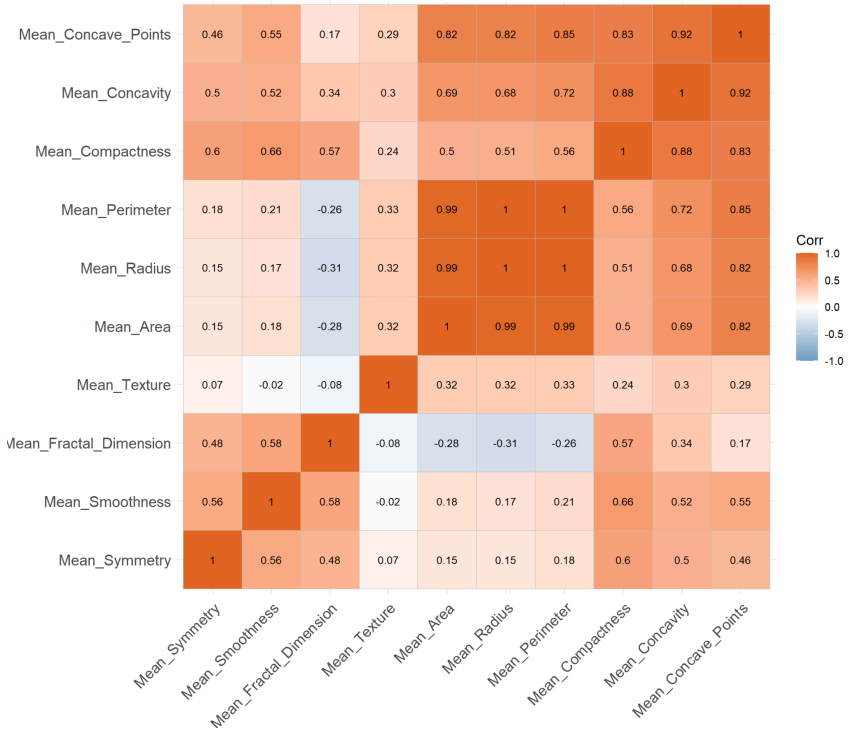

Figura 2. Mapa de correlaciones entre las covariables del estudio.

Modelos de Clasificación

Los puntos de corte óptimos, definidos como aquellos que maximizaban el *F1-score* promedio fueron: 0.63 para RL, 0.59 para RF, 0.17 para *Boosting* y 0.52 para SVM (Figuras Suplementarias C, D, E y F). Analizando el rendimiento sobre la base de validación, el modelo SVM presentó el mejor rendimiento global, alcanzando un *F1-score* de 0.951, una *precision* de 0.975 y un *recall* de 0.929, lo que indica un buen balance entre los errores tipo I y tipo II. El modelo de *Boosting* mostró el mayor *recall* (0.952), lo cual refuerza su capacidad para detectar casos positivos, aunque con una *precision* más baja (0.909) y un *F1-score* levemente inferior (0.930) al de SVM. El modelo RL mostró un desempeño uniforme, con valores de 0.905 en las tres métricas, mientras que RF se destacó por su alta *precision* (0.947), pero con el *recall* más bajo de todos (0.857), lo que redujo su *F1-score* final a 0.900 (Tabla 1).

Tabla 1. Desempeño de los 4 algoritmos en el conjunto de validación (se resalta en el valor más alto de cada columna).

Modelo	F1	Precisión	Recall
Logistic Regression	0.905	0.905	0.905
Random Forest	0.900	0.947	0.857
Boosting	0.930	0.909	**0.952**
SVM	**0.951**	**0.975**	0.929

Discusión

Los resultados obtenidos permiten comparar el desempeño de los algoritmos en un contexto de aplicación clínica sensible, como lo es el diagnóstico del cáncer de mama a partir de citología. Entre los modelos evaluados, SVM logró el mejor equilibrio entre *precision* (0.975) y *recall* (0.929), lo cual se traduce en un *F1-score* global de 0.951. Este desempeño balanceado indica que SVM logra minimizar tanto los falsos positivos como los falsos negativos, siendo una opción confiable cuando ambos tipos de error resultan clínicamente relevantes. Por otro lado, el modelo de *boosting* obtuvo el valor más alto de *recall* (0.952) entre los algoritmos comparados, lo cual lo destaca como opción más certera para reconocer verdaderos positivos (casos malignos).

Estos resultado es consistente con hallazgos previos, donde reportaron un *F1-score* de 98.3 % y un *recall* de 97.8 % para SVM con kernel RBF (Hall *et al*, 2022). Si bien nuestros valores son levemente inferiores, se encuentran dentro de un rango comparable, lo que refuerza la solidez del modelo aún sin ajuste exhaustivo de hiperparámetros. En situaciones donde la prioridad diagnóstica está centrada en evitar falsos negativos, el modelo de *Boosting* resulta el más adecuado. Este algoritmo alcanzó el mayor valor de *recall* (0.952), superando incluso al obtenido por SVM en este trabajo. Por ejemplo, trabajos previos citados reportaron un *recall* cercano al 98 % para un modelo LDA–SVM, mientras que en nuestro caso *Boosting* alcanzó el 95.2 %, lo cual sugiere que esta técnica puede ser especialmente efectiva en maximizar la sensibilidad sin comprometer excesivamente la *precision* (0.909) (Egwom *et al*, 2022). En comparación con otros trabajos, que informaron *accuracy* de hasta 98.10 % usando FFNN, o cuyo ensemble Voting logró un *accuracy* de 99.42 % (Islam *et al*, 2024, Khandoker Humayoun Kobir *et al*, 2024), nuestros resultados muestran que, si bien el *accuracy* no fue la métrica prioritaria, los valores de *F1-score* y *recall* alcanzados por SVM y *Boosting* son competitivos, especialmente considerando el uso limitado de ajuste de parámetros y la simplicidad relativa del diseño. En cuanto a RL y RF, ambos modelos mostraron desempeños correctos pero sin destacarse. RL alcanzó un *F1-score* de 0.905, mientras que RF obtuvo una *precision* alta (0.947) pero un *recall* más bajo (0.857), lo que redujo su *F1-score* final a 0.900. Estos valores, si bien aceptables, se sitúan por debajo de los mejores modelos tanto en este trabajo como en la literatura, lo que

sugiere que podrían requerir ajustes adicionales o no ser los más adecuados para contextos donde la sensibilidad diagnóstica es prioritaria.

Limitaciones y perspectivas futuras

El presente análisis se centró en comparar algoritmos ampliamente difundidos sin aplicar técnicas específicas de optimización de hiperparámetros. En consecuencia, es probable que existan combinaciones de hiperparámetros que mejoren el rendimiento de cada modelo, especialmente en el caso de *Boosting* y *SVM*, donde la sensibilidad a estos ajustes puede ser significativa.

Por otro lado, teniendo en cuenta la alta colinealidad entre ciertas variables numéricas, sería interesante evaluar si el rendimiento general de los algoritmos mejora utilizando técnicas de reducción de la dimensionalidad, como por ejemplo Análisis de Componentes Principales.

Además, si bien el foco del trabajo fue la comparación del desempeño de cada algoritmo como clasificador, podría haberse complementado el análisis con una exploración más profunda de la importancia relativa de las variables. En el caso de *Boosting* y RF, existen herramientas que permiten estimar la ganancia de información atribuida a cada predictor, lo cual puede sumar a la interpretación del modelo. Por su parte, en RL puede evaluarse también la significancia estadística de los coeficientes y su magnitud, ofreciendo un marco interpretativo más amplio sobre el sentido y peso de cada variable en la predicción.

Además de las consideraciones técnicas, el uso de modelos de aprendizaje automático en diagnóstico médico plantea desafíos éticos y de sesgo. Por ejemplo, el presente estudio se basó en el conjunto de datos WDBC, que refleja una población específica; esto limita la generalización de los resultados a otros contextos o grupos poblacionales. Asimismo, es necesario garantizar transparencia e interpretabilidad de los modelos, de modo que las decisiones clínicas derivadas de estas herramientas sean comprensibles para los profesionales de salud. Asimismo, la aplicación clínica de estos modelos requiere consideraciones éticas en torno a la transparencia, la interpretabilidad y la responsabilidad en la toma de decisiones, dado que estas herramientas deben pensarse para complementar, y no para reemplazar, el juicio profesional del médico.

Conclusión

El presente trabajo permitió comparar el desempeño de cuatro algoritmos supervisados en la clasificación de tumores mamarios a partir de variables morfológicas citológicas. Entre ellos, SVM fue el modelo con mejor desempeño global, alcanzando el *F1-score* más alto y mostrando un equilibrio sólido entre *precision* y *recall*. Por su parte, *Boosting* logró el mayor *recall*, aspecto especialmente relevante en contextos clínicos donde minimizar los falsos negativos resulta prioritario. Las diferencias observadas entre modelos podrían atribuirse a factores como la colinealidad entre predictores, los pasos de preprocesamiento aplicados o la sensibilidad propia de cada algoritmo ante los patrones del conjunto de datos. En términos generales, se cumplieron los objetivos del trabajo: se desarrollaron modelos predictivos robustos y precisos que demuestran el potencial del aprendizaje automático como herramienta complementaria para el diagnóstico del cáncer de mama. Este enfoque puede contribuir a decisiones clínicas más rápidas y confiables, reforzando el rol del análisis automatizado en entornos médicos.

Bibliografía

- Egwom, O. J., Hassan, M., Tanimu, J. J., Hamada, M., & Ogar, O. M. (2022). An LDA–SVM machine learning model for breast cancer classification. BioMedInformatics, 2(3), 345–358. https://doi.org/10.3390/biomedinformatics2030022
- Hall, K., Chang, V., & Mitchell, P. (2022). Machine learning techniques for breast cancer detection. In Proceedings of the International Conference on Complexity in Information Systems (COMPLEXIS) (pp. 116–122). SCITEPRESS.
- Islam, R., & Tarique, M. (2024). Artificial intelligence (AI) and nuclear features from the fine needle aspirated (FNA) tissue samples to recognize breast cancer. Journal of Imaging, 10(8), 201. https://doi.org/10.3390/jimaging10080201
- Kocjan, G., Bourgain, C., Fassina, A., Hagmar, B., Herbert, A., Kapila, K., Kardum-Skelin, I., Kloboves-Prevodnik, V., Krishnamurthy, S., Koutselini, H., Majak, B., Olszewski, W., Onal, B., Pohar-Marinsek, Z., Shabalova, I., Smith, J., Tani, E., Vielh, P., Wiener, H., Schenck, U., & Schmitt, F. (2008). The role of breast FNAC in diagnosis and clinical management: A survey of current practice. Cytopathology, 19(5), 271–278. https://doi.org/10.1111/j.1365-2303.2008.00610.x
- Marmot, M. G., Altman, D. G., Cameron, D. A., Dewar, J. A., Thompson, S. G., & Wilcox, M. (2013). The benefits and harms of breast cancer screening: An independent review. British Journal of Cancer, 108(11), 2205–2240. https://doi.org/10.1038/bjc.2013.177
- Rahman, M. M., Kobir, K. H., Akther, S., & Kallol, M. A. H. (2024). Ensemble machine learning for enhanced breast cancer prediction: A comparative study. International Journal of Advanced Computer Science and Applications, 15(7), 2024. https://doi.org/10.14569/IJACSA.2024.0150724
- World Health Organization. (n.d.). Breast cancer. https://www.who.int/news-room/fact-sheets/detail/breast-cancer
- Wolberg, W., Mangasarian, O., Street, N., & Street, W. (1993). Breast Cancer Wisconsin (Diagnostic) [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5DW2B

Anexo

Material Suplementario

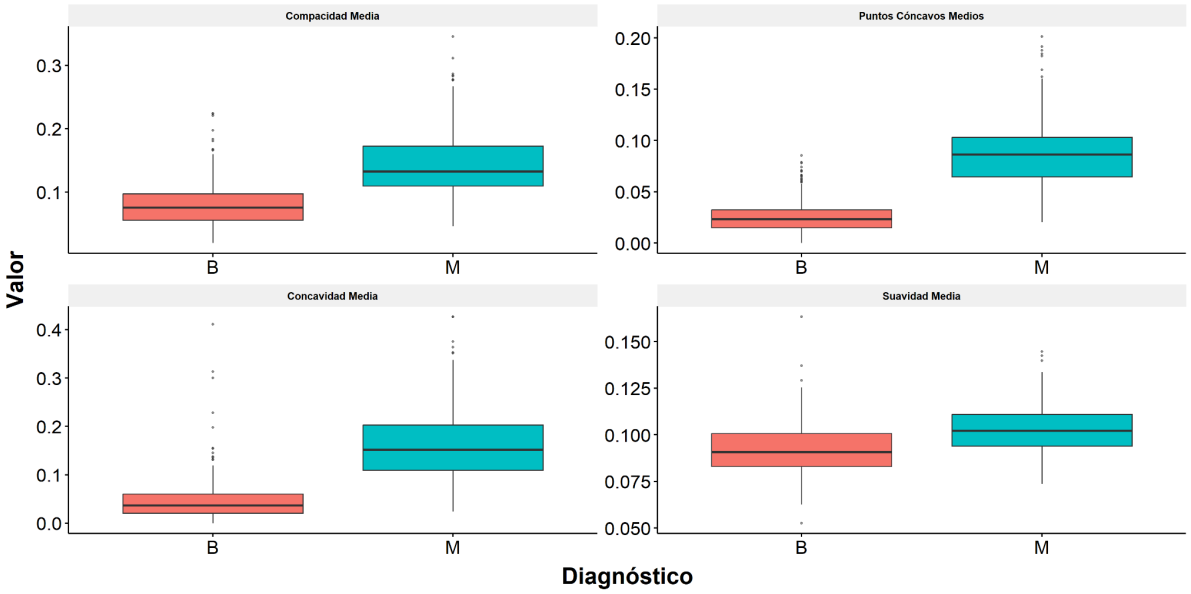

Figura A. Gráfico de cajas respecto de las variables referidas, discriminando según el diagnóstico del tumor

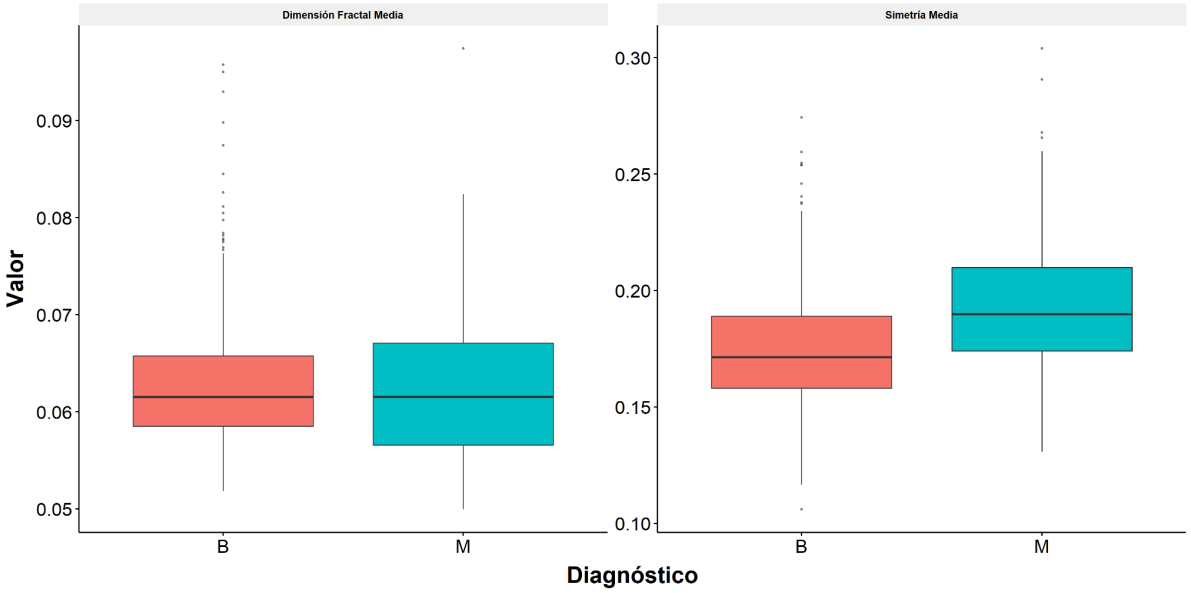

Figura B. Gráfico de cajas respecto de las variables referidas, discriminando según el diagnóstico del tumor

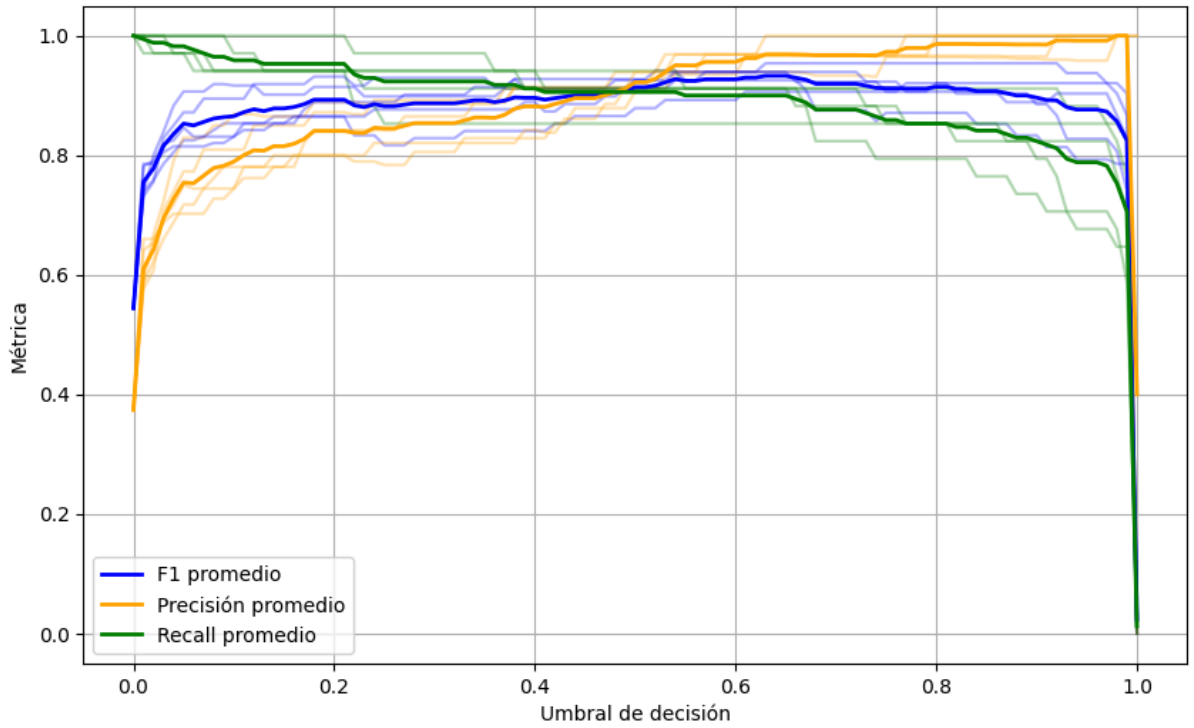

Figura C. Desempeño de RL en función del umbral de clasificación. Se muestran las curvas de *F1-score, precision* y *recall* obtenidas mediante validación cruzada de 5 pliegues. La línea engrosada resulta del promedio de los 5 valores de cada indicador.

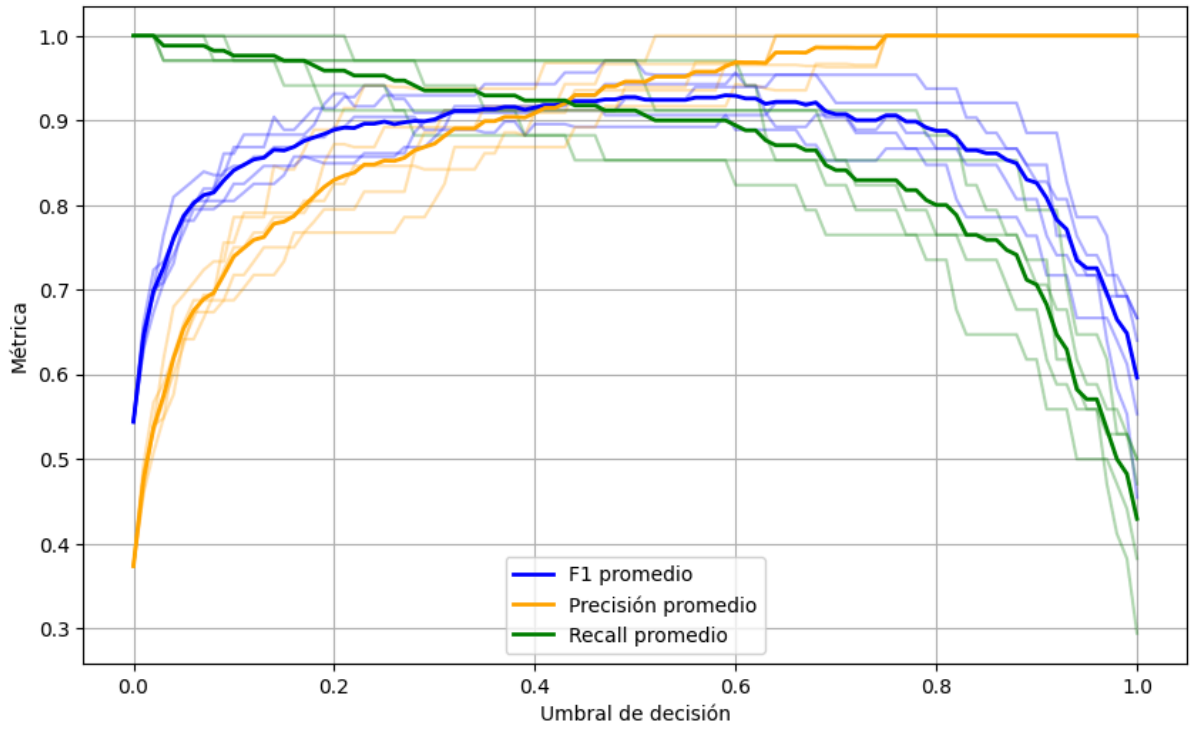

Figura D. Desempeño del *RF* en función del umbral de clasificación. Se muestran las curvas de *F1-score, precision* y *recall* obtenidas mediante validación cruzada de 5 pliegues. La línea engrosada resulta del promedio de los 5 valores de cada indicador.

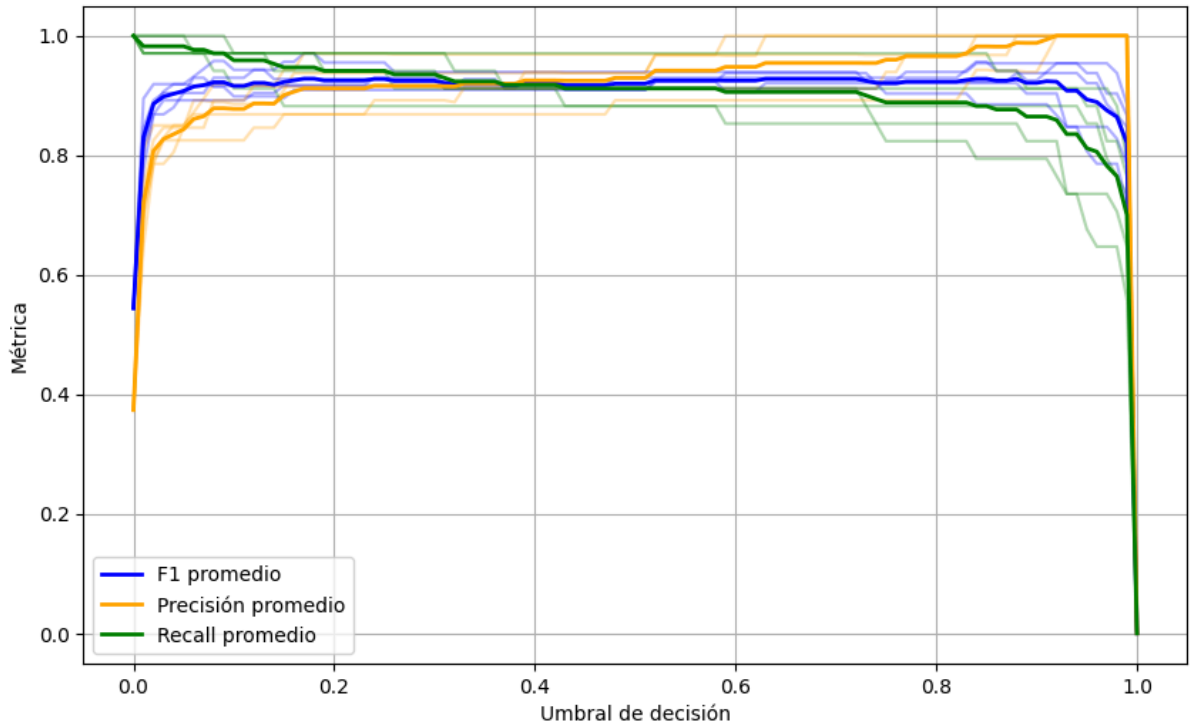

Figura E. Desempeño de *Boosting* en función del umbral de clasificación. Se muestran las curvas de *F1-score, precision* y *recall* obtenidas mediante validación cruzada de 5 pliegues. La línea engrosada resulta del promedio de los 5 valores de cada indicador.

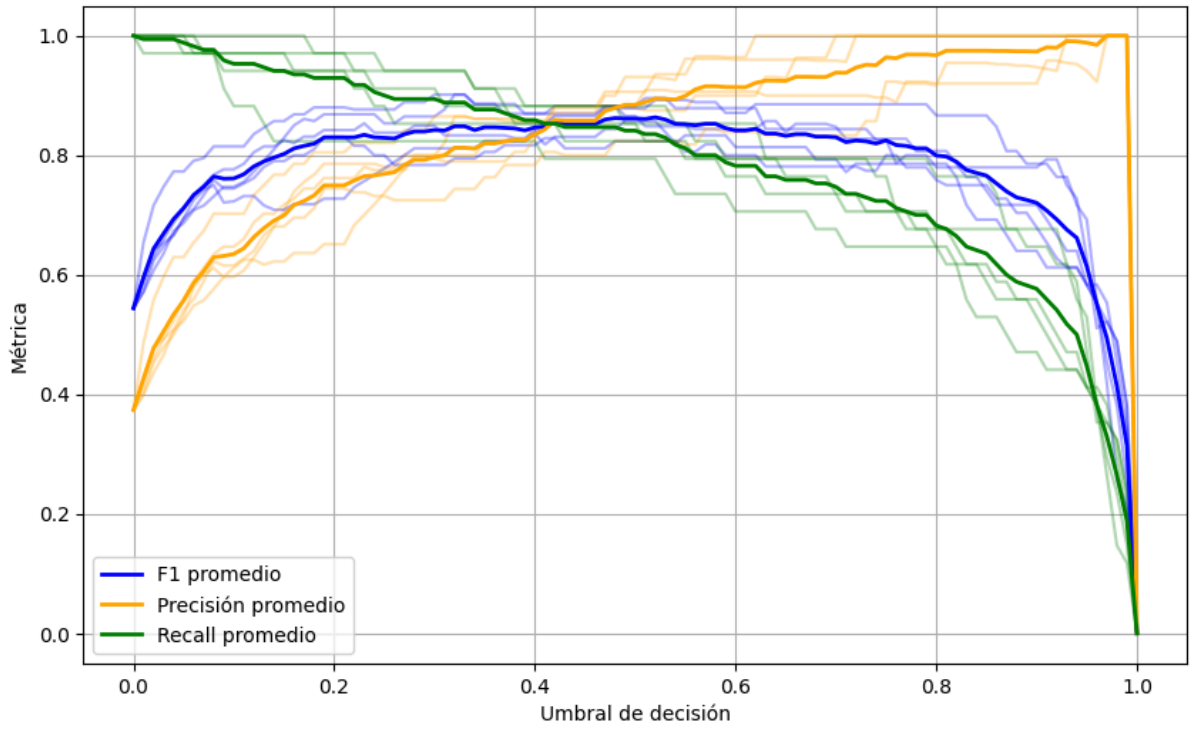

Figura F. Desempeño del SVM en función del umbral de clasificación. Se muestran las curvas de *F1-score, precision* y *recall* obtenidas mediante validación cruzada de 5 pliegues. La línea engrosada resulta del promedio de los 5 valores de cada indicador.

Métricas Utilizadas

A continuación se detalla la ecuación y el explicación de cada métrica, en donde TP = Verdadero Positivo; FP = Falso Positivo; y FN = Falso Negativo

Precision

Precision = TP / (TP + FP)

Mide **la proporción de predicciones positivas que fueron correctas**. Es decir, de todos los casos que el modelo predijo como malignos, cuántos realmente lo eran.
Una alta *precision* implica que, cuando el modelo indica que un tumor es maligno, **es muy probable que lo sea realmente**. Esto reduce la cantidad de falsos positivos (o "falsas alarmas")

Recall

***Recall* = TP / (TP + FN)**

Mide la **proporción de casos positivos que fueron correctamente identificados**. Es decir, cuántos tumores malignos reales el modelo logró detectar.
Un alto *recall* implica que el modelo detecta casi todos los tumores malignos. Es crucial porque minimiza los falsos negativos, que son pueden ser los más peligrosos en este caso.

F1-score

F1 = 2 · (Precision · Recall) / (Precision + Recall)

El *F1-score* es la media armónica entre *precision* y *recall*. Es útil cuando hay un desequilibrio entre clases y cuando se necesita un compromiso entre falsos positivos y falsos negativos.

Código

En el siguiente repositorio se encuentran tanto el conjunto de datos así cómo el código utilizado para realizar los análisis del presente trabajo, incluyendo la realización de gráficos y figuras, y la ejecución de los modelos de predicción